



Faculdade de Ciências da Universidade do Porto

Licenciatura de Inteligência Artificial e Ciência de Dados

Evaluating Logarithmic Number Systems for Low-Resource Language Models

github.com/specs-feup/LNS-Library

Autor

Henrique dos Santos Teixeira

Junho de 2026

Resumo

O Logarithmic Number System (LNS) representa os valores como logaritmos de vírgula fixa em complemento para dois, permitindo que a multiplicação e a divisão sejam realizadas através de simples adições e subtrações inteiras, e que a raiz quadrada se reduza a um deslocamento aritmético à direita. Esta propriedade elimina os multiplicadores de mantissa do hardware, reduzindo significativamente a área e o consumo de energia, características especialmente relevantes para a inferência de redes neuronais em dispositivos de baixos recursos.

Este estágio, realizado no INESC TEC, teve quatro objectivos principais: em primeiro lugar, a continuação de trabalho realizado previamente com o LNS, que foi focado nas operações aritméticas, ao adicionar operações de comparação e conversão de FP/BF para LNS e vice-versa, em segundo lugar, criar uma biblioteca de emulação LNS para criar uma base de exploração do formato, em terceiro lugar, realizar uma comparação estatística da precisão aritmética entre LNS e BF em múltiplas bandas de magnitude de operando e, em quarto lugar, suportar inferência em LLMs, nomeadamente a arquitectura Llama 2.

No regime de 8 bits, o **bf8** é o claro vencedor, no entanto, o **lns8** tem apenas uma pequena desvantagem sob o **bf8** na multiplicação e divisão em todas as bandas de magnitude testadas, enquanto tem uma maior na adição, subtracção e fidelidade de round-trip — padrão que reflecte directamente a natureza do LNS, onde a multiplicação e a divisão são operações exactas no domínio logarítmico, ao passo que a adição e a subtracção requerem funções de correcção não-lineares sujeitas a erro de aproximação. No regime de 16 bits, o **bf16** domina o erro relativo na multiplicação, adição e subtracção, enquanto o **lns16** mantém vantagem consistente na divisão em todas as bandas e no erro absoluto da multiplicação — reflectindo a distribuição assimétrica de precisão do **bf16**, que favorece valores próximos de zero. Nos testes numéricos, ambos os formatos de 8 bits têm um erro relativo equivalente abaixo de 1.0 em tarefas de acumulação intensiva como a progressão geométrica e a série harmónica alternada, evidenciando as limitações inerentes à precisão reduzida, enquanto que em 16 bits, o LNS apresenta um erro significativamente inferior ao BF. Também no regime de 16 bits, o **lns16** apresenta erro superior ao **bf16** em funções como a GELU, cuja avaliação envolve composição de operações não-lineares pouco favoráveis ao domínio logarítmico, no entanto, o **lns16** apresenta um menor erro na Softmax face ao **bf16**. A inferência do modelo *stories15M* e *stories42M* com pesos convertidos directamente de **fp32** para **lns16** produz texto coerente, confirmando a viabilidade prática do formato para tarefas de inferência de maior complexidade.

Agradecimentos

Agradeço ao meu supervisor Prof. Nuno Paulino pela orientação constante e pelo rigor com que acompanhou este trabalho, bem como aos co-supervisores Luís Sousa e Guilherme Oliveira pelo apoio técnico e pelas discussões produtivas ao longo de todo o estágio. Agradeço também ao INESC TEC pelo ambiente de investigação e pelos recursos disponibilizados.

Índice

1	Introdução	2
2	Estado da Arte e Enquadramento	3
2.1	O Logarithmic Number System	3
2.2	Estado da Arte	4
2.2.1	LNS em Aceleração de Redes Neurais	4
2.2.2	Formatos Alternativos: Posits e Microscaling	4
2.2.3	Compressão e Quantização de LLMs	5
2.3	Ferramentas e Tecnologias	5
2.4	Enquadramento	5
2.4.1	Representações XF e XMB	5
2.4.2	Algoritmo Greedy	5
2.4.3	Formatos Suportados	6
3	Descrição do Trabalho	7
3.1	Comparações em LNS e Conversão FP/BF $\leftrightarrow$ LNS	7
3.1.1	Comparações em LNS	7
3.1.2	Funções de Conversão FP/BF $\leftrightarrow$ LNS	7
3.2	Biblioteca de Emulação LNS	8
3.2.1	Arquitetura da Biblioteca	8
3.3	Comparação de Precisão Aritmética: LNS vs. BF	9
3.3.1	Metodologia	9
3.3.1.1	Benchmark 1 — Precisão por Banda de Magnitude	9
3.3.1.2	Benchmark 2 — Testes Numéricos	9
3.3.2	Resultados e Análise	10
3.3.2.1	Benchmark 1 — Erro por Banda	10
3.3.2.2	Benchmark 1 — Heatmaps de Vencedor por Operação $\times$ Banda	11
3.3.2.3	Benchmark 2 — Testes Numéricos	12
3.4	Inferência na Arquitetura Llama 2	13
3.4.1	Conversão de Modelos fp32 para lns16 e bf16	13
3.4.2	Inferência lns16 vs bf16	13
3.4.3	Inferência lns8 vs bf8	13
3.4.4	Resultados de Inferência	14
3.4.4.1	Stories 15M	14
3.4.4.1.1	lns16 (XF)	14
3.4.4.1.2	lns16 (XMB)	14
3.4.4.1.3	bf16	14
3.4.4.2	Stories 42M	15
3.4.4.2.1	lns16 (XF)	15
3.4.4.2.2	lns16 (XMB)	15
3.4.4.2.3	bf16	15
3.4.5	Análise	15
4	Conclusão e Trabalho Futuro	16
	Bibliografia	17

Lista de Figuras

- Figura 1 Erro relativo e absoluto médio por banda para cada operação e par de formatos. (p é o número de bits da parte inteira do exponte em LNS — 2^{-p+1} é o número mais pequeno que ambos os formatos conseguem representar) 10
- Figura 2 Comparação de heatmaps de vencedor por operação $\times$ banda para os formatos de 8 bits (**lns8** vs **bf8**). À esquerda: erro relativo médio; À direita: erro absoluto médio. 11
- Figura 3 Erro relativo dos testes numéricos para todos os formatos. Os empates são anotados quando a diferença relativa entre lns e bf é inferior a 5%. 12
- Figura 4 Erro absoluto dos testes numéricos para todos os formatos. Os empates são anotados quando a diferença relativa entre lns e bf é inferior a 5%. 12

Lista de Tabelas

- Tabela 1 Especificações dos formatos LNS suportados. 6

Abreviaturas e Siglas

BF	Brain Float
CPU	Central Processing Unit
DSP	Digital Signal Processing block
FP	Floating Point
FPGA	Field-Programmable Gate Array
FPU	Floating Point Unit
HLS	High-Level Synthesis
LLM	Large Language Model
LNS	Logarithmic Number System
LNSU	Logarithmic Number System Unit
LUT	Look-Up Table
RISC	Reduced Instruction Set Computer
XF	Spline format storing (x, f) point pairs
XMB	Spline format storing (x, m, b) segment coefficients

1 Introdução

A crescente utilização de redes neuronais em dispositivos de baixos recursos tem intensificado a necessidade de plataformas de computação energeticamente eficientes. Embora o treino de modelos seja frequentemente realizado com aritmética de Floating Point (FP) de 32 bits (fp32), a fase de inferência é significativamente mais tolerante à perda de precisão. Como a aritmética IEEE 754 é dispendiosa em termos de hardware e consumo de energia, existe um esforço crescente de investigação orientado para representações numéricas alternativas, incluindo Brain Float (BF), Low-Precision Floating Point, vírgula fixa, posits e outros formatos personalizados.

O **Logarithmic Number System** (LNS) constitui uma alternativa particularmente atraente. Ao representar os valores como logaritmos de vírgula fixa em complemento para dois, o LNS transforma a multiplicação e a divisão em adições e subtracções inteiras e a raiz quadrada num simples deslocamento aritmético à direita. Estas propriedades eliminam os multiplicadores de mantissa do hardware, o que pode reduzir substancialmente a área e o consumo de energia. Adicionalmente, o LNS oferece maior densidade de representação na gama $[-1, 1]$, onde se concentram os pesos típicos de redes neuronais treinadas.

O trabalho realizado neste estágio insere-se num projecto mais amplo desenvolvido no INESC TEC, cujo objectivo é a continuação do desenvolvimento de uma extensão LNS num CPU RISC-V (RISC++), implementado através de High Level Synthesis (HLS), um processo de design automatizado que converte software abstrato (como C, C++ ou SystemC) em circuitos digitais de hardware (Register-Transfer Level — RTL). Num trabalho anterior, defini em conjunto com o meu colega, José Paradela, dois formatos LNS, `lns16 Q8.7` e `lns8 Q4.3`, e implementei uma LNSU com as operações `add`, `sub`, `mul`, `div` e `sqrt` e na qual as funções não-lineares intrínsecas à adição e subtração eram aproximadas por splines lineares gerados por um algoritmo greedy, obtendo precisão de 2^{-7} e 2^{-3} , respetivamente, com tabelas de no máximo 324 bytes. O presente estágio teve por objectivo continuar e aprofundar esse trabalho em quatro direcções principais:

1. **adicionar operações de comparação e conversão** de FP/BF $\leftrightarrow$ LNS;
2. **criar uma biblioteca de emulação LNS** para criar uma base de exploração do formato;
3. **comparar o LNS ao BF** em precisão aritmética com testes estatísticos;
4. **suportar inferência em LLMs**, nomeadamente a arquitectura Llama 2.

Este relatório está estruturado da seguinte forma:

- a Secção 2 apresenta o enquadramento e estado da arte;
- a Secção 3 descreve em detalhe o trabalho realizado;
- a Secção 4 apresenta as conclusões e perspectivas de trabalho futuro.

2 Estado da Arte e Enquadramento

2.1 O Logarithmic Number System

No LNS, um número real não nulo x é representado por um bit de sinal S_x e um logaritmo binário de vírgula fixa L_x em complemento para dois:

$$S_x = \begin{cases} 1 & \text{se } x < 0 \\ 0 & \text{se } x \geq 0 \end{cases} \quad L_x = \log_2(|x|) \quad x = (-1)^{S_x} \cdot 2^{L_x}$$

O expoente L_x é um número de vírgula fixa em complemento para dois, com uma parte inteira e uma parte fraccionária. Valores negativos de L_x representam magnitudes em $(0, 1)$ e valores positivos representam magnitudes em $(1, +\infty)$, o que confere ao LNS maior densidade de representação na gama $[-1, 1]$ — precisamente onde se concentram os pesos típicos de redes neuronais treinadas.

Esta representação transforma várias operações em operações mais simples.

$$\begin{aligned} z = x \cdot y &\Rightarrow L_z = L_x + L_y, \quad S_z = S_x \oplus S_y \\ z = \frac{x}{y} &\Rightarrow L_z = L_x - L_y, \quad S_z = S_x \oplus S_y \\ z = x^{2^n} &\Rightarrow L_z = L_x \ll n, \quad S_z = 0 \quad (\forall n \geq 1) \\ z = x^{2^{-n}} &\Rightarrow L_z = L_x \gg n, \quad S_z = S_x \quad (\forall x \geq 0) \end{aligned}$$

A multiplicação reduz-se a uma adição inteira dos expoentes, a divisão a uma subtração e as potências ou raízes de base 2 a meros deslocamentos lógicos à esquerda ou à direita (shifts) — todos significativamente mais simples e eficientes em termos energéticos do que as suas contrapartes em vírgula flutuante, que requerem manipulação explícita de mantissas. Parhami [1] constitui a referência canónica do LNS, descrevendo-o como uma alternativa estruturalmente distinta à vírgula flutuante: ao representar os valores como logaritmos de vírgula fixa em complemento para dois, o sistema transforma a multiplicação em adição inteira e a divisão em subtracção inteira.

A adição e a subtracção requerem cuidado adicional. Para $z = x \pm y$ com $|x| \geq |y|$, a derivação parte de:

$$\begin{aligned} z = x \pm y &\Rightarrow L_z = \log_2(|x \pm y|), \quad S_z = S_x \\ &= \log_2(|2^{L_x} \pm 2^{L_y}|) \\ &= \log_2(2^{L_x} \cdot |1 \pm 2^{L_y-L_x}|) \\ &= L_x + \log_2(|1 \pm 2^{L_y-L_x}|) \\ &= L_x + \log_2(1 \pm 2^{L_y-L_x}) \end{aligned}$$

Definindo $t = L_y - L_x \leq 0$ (garantido por troca de operandos se necessário), introduz-se a chamada **função de Gauss logarítmica de adição**:

$$f^+(t) = \log_2(1 + 2^t), \quad t \in (-\infty, 0]$$

e, analogamente para a subtracção, a **função de Gauss logarítmica de subtracção**:

$$f^-(t) = \log_2(1 - 2^t), \quad t \in (-\infty, 0)$$

A função f^+ é suave e limitada em $(-\infty, 0]$. Cresce monotonicamente de 0 quando $t \rightarrow -\infty$ até 1 em $t = 0$. As suas primeira e segunda derivadas são:

$$(f^+)'(t) = \frac{2^t}{1+2^t}, \quad (f^+)'(t) = \ln(2) \cdot \frac{2^t}{(1+2^t)^2}$$

Ambas são sempre positivas, monotonicamente crescentes, e aproximam-se de 0 quando $t \rightarrow -\infty$ e dos valores $\frac{1}{2}$ e $\frac{\ln(2)}{4}$ em $t = 0$. A suavidade de f^+ torna-a favorável à aproximação: poucas peças são suficientes para atingir alta precisão.

A função f^- está definida apenas em $(-\infty, 0)$. Quando $t \rightarrow 0^-$, tem-se $f^-(t) \rightarrow -\infty$, devido à singularidade do logaritmo em zero. As suas derivadas:

$$(f^-)'(t) = -\frac{2^t}{1-2^t}, \quad (f^-)'(t) = -\ln(2) \cdot \frac{2^t}{(1-2^t)^2}$$

são sempre negativas e divergem para $-\infty$ quando $t \rightarrow 0^-$. A segunda derivada não limitada perto de $t = 0$ é a razão fundamental pela qual a função de subtração requer significativamente mais intervalos do que a função de adição para atingir a mesma precisão de aproximação — assimetria confirmada analiticamente e documentada por Coleman et al. [2], que demonstram que f^- requer significativamente mais entradas de LUT do que f^+ devido à singularidade em $t = 0$, explorando ainda compromissos entre dimensão das tabelas e precisão, o que motiva directamente a representação XMB adoptada. O autor cataloga as principais dificuldades — nomeadamente a complexidade das funções de correcção f^+ e f^- — e revê estratégias para a sua avaliação eficiente. A avaliação eficiente destas funções é o principal desafio de implementação do LNS. As derivações detalhadas encontram-se em docs/docs.pdf no repositório do projecto.

2.2 Estado da Arte

2.2.1 LNS em Aceleração de Redes Neurais

Christ et al. [3] apresentam uma unidade LNS de baixa precisão para aceleradores de redes neurais em FPGA Kintex-7, obtendo degradação de apenas 3% na precisão top-1 no MNIST com 12 500 a 14 000 LUTs. A arquitectura partilha o objectivo de minimizar o custo das funções de correcção via LUTs de dimensão reduzida. A diferença central é de escala: enquanto Christ et al. [3] focam redes convolucionais compactas, o presente trabalho estende a análise para inferência em modelos Llama 2 (stories15M e stories42M), com cargas de trabalho substancialmente mais intensas.

2.2.2 Formatos Alternativos: Posits e Microscaling

Wu et al. [4] apresentam o PPU, uma extensão RISC-V para aritmética posit vectorial. Os posits oferecem maior precisão efectiva por bit em certas gamas, mas a custos de hardware consideráveis: o PERCIVAL requer $2,94\times$ mais LUTs e $3,0\times$ mais flip-flops do que uma FPU convencional. Em contraste, a LNSU do trabalho anterior requer até 45% menos LUTs, 48% menos flip-flops e 58% menos DSPs, com frequências 29%–36% superiores. Os formatos de microscaling (MX) [5], [6] adoptam abordagem diferente: introduzem um expoente partilhado por blocos de elementos, reduzindo o custo de representação sem alterar a aritmética. O MXDOTP [6] obtém acelerações de até $3,4\times$ face ao fp32 em multiplicações de matrizes. Estes formatos são ortogonais ao LNS e poderiam, em princípio, ser combinados.

2.2.3 Compressão e Quantização de LLMs

Han et al. [7] demonstraram que redes neuronais profundas toleram quantização agressiva dos pesos sem degradação significativa, desde que a estrutura do modelo seja preservada — motivação directa para a conversão directa `fp32` $\rightarrow$ `lns16` sem re-treino adoptada neste trabalho. A arquitectura Llama 2 nos modelos *TinyStories* [8] utiliza multi-head attention e normalização RMS, operações cujo comportamento numérico em formatos de baixa precisão é menos estudado do que o das redes convolucionais clássicas. A produção de texto coerente após conversão directa confirma que o `lns16 Q8.7` é uma alternativa prática ao `bf16` para inferência em dispositivos de recursos limitados.

2.3 Ferramentas e Tecnologias

O desenvolvimento foi realizado em C++ standard, sem dependências externas além da biblioteca matemática padrão. A biblioteca de emulação LNS (`lnssim.hpp`) e a biblioteca de emulação BF (`bfloatsim.hpp`) são cabeçalhos auto-contidos que implementam os respectivos tipos numéricos como templates C++. A geração das tabelas de spline é realizada por uma ferramenta autónoma (`spline`) que ajusta aproximações por troços às funções f^+ e f^- e escreve os resultados em ficheiros binários `.lns`. Os modelos de linguagem utilizados nos testes de inferência são da família *TinyStories* [8] (`stories15M` e `stories42M`), baseados na arquitectura Llama 2.

2.4 Enquadramento

2.4.1 Representações XF e XMB

O trabalho anterior aproximou f^+ e f^- com piecewise splines lineares gerados por um algoritmo greedy. Dado um conjunto de $n + 1$ pontos $\{(x_i, f_i)\}_{i=0}^n$, a fórmula da interpolação de um spline linear para um intervalo $[x_{i-1}, x_i]$ é:

$$\text{LS}_i(x) = \frac{(x_i - x)f_{i-1} + (x - x_{i-1})f_i}{h_i}, \quad h_i = x_i - x_{i-1}$$

Isto é a representação XF. Uma forma equivalente é:

$$\text{LS}_i(x) = m_i \cdot x + b_i, \quad m_i = \frac{f_i - f_{i-1}}{h_i}, \quad b_i = \frac{f_{i-1}x_i - f_i x_{i-1}}{h_i}$$

Esta é a representação XMB. Precomputa o declive m_i e a interceção b_i por intervalo, reduzindo a avaliação em runtime a um simples multiply-add. O trade-off é o aumento no uso da memória: XF requiere $4 \cdot (n + 1)$ bytes para o `lns16`, enquanto o XMB requiere $6 \cdot (n + 1)$ bytes.

A fórmula para o upper bound do error de um spline linear é:

$$\varepsilon \leq \frac{1}{8} \max_{[a,b]} |f''(x)| h_i^2$$

2.4.2 Algoritmo Greedy

O algoritmo greedy começa com as duas extremidades do intervalo inicial $([-8, 0])$ e iterativamente adiciona o ponto intermédio do intervalo com maior estimativa de erro:

$$\varepsilon_i^+ \leq \frac{\ln(2) \cdot 2^{x_i} \cdot h_i^2}{8(1 + 2^{x_i})^2}$$

$$\varepsilon_i^- \leq \frac{\ln(2) \cdot 2^{x_i} \cdot h_i^2}{8(1 - 2^{x_i})^2}$$

Como a upper bound é monótona e crescente para ambas as funções, o intervalo a separar em dois é sempre aquele com maior h_i ponderado pela curvatura local. O mínimo tamanho de intervalo permitido é $2 \cdot 2^{-f}$, onde f é a parte fracionária do formato LNS.

2.4.3 Formatos Suportados

Formato	Bit de sinal	Bits inteiros	Bits fraccionários	Gama de valores
lns8 Q4.3	1	4	3	2^{-8} a $2^{7.875}$
lns16 Q8.7	1	8	7	2^{-128} a $2^{127.992}$

Tabela 1: Especificações dos formatos LNS suportados.

O formato `lns16 Q8.7` tem 7 bits de mantissa efectiva, o mesmo que o `bf16`, tornando a comparação directa entre os dois formatos particularmente relevante.

3 Descrição do Trabalho

3.1 Comparações em LNS e Conversão FP/BF $\leftrightarrow$ LNS

3.1.1 Comparações em LNS

Sejam x e y dois operandos, podemos estabelecer as seguintes 5 comparações: $x < y, x \leq y, x = y, x \geq y, x > y$, com apenas duas delas: $x < y$ e $x = y$.

Para determinar se x é igual a y , basta comparar os bits um a um, logo, é equivalente a fazer uma comparação de inteiros.

Para determinar se x é menor do que y :

$$\text{LNS-LessThan}(x, y) = \begin{cases} \text{true} & \text{se } \text{sign}(x) = 1 \wedge \text{sign}(y) = 0 \\ \text{exponent}(x) > \text{exponent}(y) & \text{se } \text{sign}(x) = \text{sign}(y) = 1 \\ \text{exponent}(x) < \text{exponent}(y) & \text{se } \text{sign}(x) = \text{sign}(y) = 0 \\ \text{false} & \text{caso contrário} \end{cases}$$

As restantes comparações são estabelecidas através de rescritas das inequações:

$$x \leq y \Leftrightarrow x < y \vee x = y$$

$$x \geq y \Leftrightarrow y \leq x$$

$$x > y \Leftrightarrow y < x$$

3.1.2 Funções de Conversão FP/BF $\leftrightarrow$ LNS

Uma componente importante do trabalho foi a análise formal das funções de conversão entre FP e LNS. Dado que $x_{\text{fp}} = (-1)^{S_x} \cdot (1 + m_x) \cdot 2^{e_x - 127}$ e $x_{\text{lns}} = (-1)^{S_x} \cdot 2^{L_x}$, a igualdade impõe $L_x = e_x - 127 + \log_2(1 + m_x)$, o que define as funções de conversão:

$$\text{float2lns}(S_x, e_x, m_x) := (-1)^{S_x} \cdot (e_x - 127 + \log_2(1 + m_x))$$

$$\text{lns2float}(S_x, L_{i_x}, L_{f_x}) := (-1)^{S_x} \cdot (1 + (2^{L_{f_x}} - 1)) \cdot 2^{L_{i_x} + 127}$$

Ambas as expressões não lineares das funções de conversão, $\log_2(1 + m_x)$ e $2^{L_{f_x}} - 1$, têm domínio $[0, 1)$ e podem ser aproximadas com splines lineares. Os upper bounds do erro correspondentes foram derivados analiticamente, seguindo a mesma metodologia aplicada às funções de Gauss logarítmicas:

$$\varepsilon_{\text{float2lns}} \leq \frac{1}{8} \cdot \frac{1}{\ln(2)} \cdot \frac{1}{(1 + x_{i-1})^2} \cdot h_i^2$$

$$\varepsilon_{\text{lns2float}} \leq \frac{1}{8} \cdot \ln(2) \cdot 2^{2x_i} \cdot h_i^2$$

3.2 Biblioteca de Emulação LNS

3.2.1 *Arquitectura da Biblioteca*

A biblioteca de emulação LNS é implementada como um conjunto de cabeçalhos C++ auto-contidos que partilham a mesma interface template `lns<N, I, F>`, parametrizada pela largura total em bits (N), pelo número de bits inteiros (I) e pelo número de bits fraccionários (F). Esta interface expõe os operadores aritméticos C++ standard (+, -, *, /, comparações, etc.) e permite que o mesmo código de aplicação seja compilado para dois backends distintos por simples substituição do `#include`:

- `lnssim.hpp` — emulação em software com tabelas de spline pré-calculadas (formato `.lns`), destinado a simulação e testes no host. A aritmética de adição e subtracção é resolvida por pesquisa na tabela XF ou XMB, dependendo de qual foi carregada via `lns{8,16}_read_tables()`. Todas as restantes operações são exactas no domínio logarítmico.
- `lns.hpp` — interface para alvo em hardware que mapeia cada operador directamente para a instrução RISC-V personalizada correspondente via assembly inline, destinado à execução no núcleo RISC++ em FPGA.

A biblioteca também inclui `bfloatsim.hpp`, um cabeçalho auto-contido que implementa os tipos `bf8` (E4M3) e `bf16` (E7M8) como templates C++. O `bf16` é simulado truncando os 16 bits inferiores de uma representação `fp32` (round-to-zero); o `bf8` aplica a mesma estratégia com a máscara E4M3. Ambos os tipos expõem a mesma interface que os tipos LNS correspondentes, permitindo que o mesmo benchmark seja instanciado sobre qualquer combinação de formatos.

Os tipos concretos utilizados ao longo deste trabalho são definidos como:

```
typedef lns<32, 8, 23> lns32; // acumulador de alta precisão
typedef lns<16, 8, 7> lns16; // formato principal Q8.7
typedef lns<8, 4, 3> lns8; // formato de 8 bits Q4.3
```

`lns32` é utilizado como referência de verdade: os erros de `lns8` e `lns16` são calculados relativamente a `lns32`, enquanto os erros de `bf8` e `bf16` são calculados relativamente a `fp32` e `f64`, respectivamente. Esta assimetria é intencional — cada formato é julgado contra uma versão de maior precisão de si próprio.

A biblioteca pode ser integrada em qualquer projecto C++ com uma única directiva `#include`, sem dependências externas e sem sistema de build específico.

3.3 Comparação de Precisão Aritmética: LNS vs. BF

3.3.1 Metodologia

Foi desenvolvido um benchmark abrangente (*bench/*) que compara a precisão aritmética de LNS e BF nos pares `lns8/bf8` e `lns16/bf16`, cobrindo duas dimensões: precisão por banda de magnitude em cinco operações aritméticas (Benchmark 1) e precisão em nove testes numéricos de nível algorítmico (Benchmark 2).

3.3.1.1 Benchmark 1 — Precisão por Banda de Magnitude

As cinco operações avaliadas são: conversão e retorno (*round-trip*), multiplicação, divisão, adição e subtração, parametrizadas por bandas de magnitude $[lo, hi]$ (potências de dois consecutivas). Dentro de cada banda, os operandos são amostrados log-uniformemente para evitar acumulação em fronteiras de potências de dois.

A métrica primária é diferenciada por operação: erro relativo médio (*avg_rel*) para *round-trip*, multiplicação e divisão (invariante à escala); erro absoluto médio (*avg_abs*) para adição e subtração, onde o erro relativo diverge em situações de cancelamento. Aplica-se um filtro de cancelamento: pares em que $|a + b| < 2^{\{-f\}} \cdot \max(|a|, |b|)$ são descartados, onde f é o número de bits fraccionários.

Os vencedores são determinados por teste Mann-Whitney U bilateral com $n = 100,000$ amostras ($p < 0.01$, $|r| \geq 0.05$).

3.3.1.2 Benchmark 2 — Testes Numéricos

Nove testes de nível algorítmico: progressão geométrica, norma euclidiana, série harmónica alternada (Leibniz), acumulação da soma de $\frac{\pi^2}{6}$ com a definição da série do Basel Problem tanto do primeiro até ao termo N e o reverso, sigmoid, GELU, soma de softmax e RMSNorm. LNS é avaliado contra `lns32`; BF contra `f32`. Para cada teste em formato de 16 bits, é testada soma acumulada em 32 bits, `lns16` testado com `lns32` e `fp32`, enquanto que o `bf16` tem soma acumulada apenas com `fp32`. Empates declarados quando a diferença relativa entre erros é inferior a 5%.

3.3.2 Resultados e Análise

3.3.2.1 Benchmark 1 — Erro por Banda

Arithmetic accuracy — 8-bit & 16-bit formats




Figura 1: Erro relativo e absoluto médio por banda para cada operação e par de formatos. (p é o número de bits da parte inteira do expoente em LNS — 2^{-p+1} é o número mais pequeno que ambos os formatos conseguem representar)

O erro relativo é aproximadamente invariante à banda para todos os formatos; a diferença LNS/BF é essencialmente constante ao longo das décadas de magnitude.

O erro absoluto cresce com a magnitude para todos os formatos. Os gráficos de adição, subtração, multiplicação e round-trip mostram o erro absoluto de ambos os formatos a crescer, consistente com a acumulação de erro na correcção de adição em log-space.

3.3.2.2 Benchmark 1 — Heatmaps de Vencedor por Operação × Banda

Heatmap — winner per op × band (relative error | absolute error)




Figura 2: Comparação de heatmaps de vencedor por operação × banda para os formatos de 8 bits (lns8 vs bf8). À esquerda: erro relativo médio; À direita: erro absoluto médio.

Em erro relativo e absoluto, o **bf8** vence em todas as três bandas sem empates. O resultado de multiplicação e divisão é digno de nota: embora a aritmética LNS seja exata no expoente e o **bf8** sofra com apenas 3 bits de mantissa, este permanece mais preciso. Adicionalmente, o resultado de adição e subtração confirma a fraqueza conhecida do LNS, onde o termo de correcção aproximado por tabela introduz um erro que a adição directa do **bf8** não sofre.

Em erro absoluto, o **lns16** vence a multiplicação em 7 das 8 bandas e a divisão em todas as 8; o **bf16** vence adição e subtração em todas as bandas. Em erro relativo, o **bf16** inverte o resultado na multiplicação. Esta inversão é significativa: o **lns16** é preferível quando os operandos permanecem numa gama limitada e a fidelidade absoluta importa; o **bf16** é preferível quando a precisão relativa tem de ser mantida num intervalo dinâmico amplo.

3.3.2.3 Benchmark 2 — Testes Numéricos




Figura 3: Erro relativo dos testes numéricos para todos os formatos. Os empates são anotados quando a diferença relativa entre lns e bf é inferior a 5%.




Figura 4: Erro absoluto dos testes numéricos para todos os formatos. Os empates são anotados quando a diferença relativa entre lns e bf é inferior a 5%.

Os resultados numéricos são consistentes com a avaliação das operações por banda: em qualquer workload dominado pela subtração ou adição, a adição corretamente arredondada do **bf16** dá-lhe uma vantagem visível. As variantes de acumulação em 32 bits mostram que esta diferença é praticamente devida à precisão na acumulação em vez do formato: **lns16_lns32_acc** e **lns16_f32acc** recuperam bastante em testes como **pi2_over6**, **softmax_sum** e **rmsnorm_denom**. Em variantes de puras sequências de multiplicação as variantes de 16 bits em LNS têm melhor precisão do que BF, no entanto, em 8 bits empatam (**geometric_progression**).

3.4 Inferência na Arquitetura Llama 2

3.4.1 Conversão de Modelos **fp32** para **lms16** e **bf16**

Foram desenvolvidas duas ferramentas de conversão de pesos em `tinystories/convert/`: `convert_lms16.cpp` e `convert_bf16.cpp`. Ambas operam em modo de streaming em lotes de 4096 pesos de cada vez, mantendo o cabeçalho de configuração inalterado e convertendo apenas os pesos e os scores do tokenizer.

A conversão $\text{fp32} \rightarrow \text{lms16}$ aplica, para cada peso x_{fp32} :

$$L_x = (e_x - 127) + \log_2(1 + m_x)$$

onde e_x é o expoente IEEE 754 e m_x é a mantissa normalizada em $[0, 1)$. O termo $\log_2(1 + m_x)$ é avaliado via a tabela `float2lms` pré-calculada pelo algoritmo greedy. Esta conversão não requer re-treino. A conversão $\text{fp32} \rightarrow \text{bf16}$ trunca os 16 bits inferiores da representação fp32 , mantendo sinal, 8 bits de expoente e 7 bits de mantissa.

3.4.2 Inferência **lms16** vs **bf16**

O ficheiro `tinystories/tiny/tiny_lms16.cpp` implementa o ciclo completo de inferência do transformer Llama 2 usando exclusivamente **lms16** para pesos e activaões. As operações fundamentais foram re-implementadas com o tipo **lms16**: multiplicação de matrizes (*matmul*), atenção multi-cabeça, normalização RMS, SiLU e softmax.

A normalização RMS é sensível ao erro de aproximação da adição LNS, uma vez que a soma dos quadrados envolve muitas adições sucessivas. Adoptou-se por isso uma abordagem híbrida em que essa soma é calculada em **fp32** e convertida para **lms16**, mantendo todas as restantes operações em LNS16. Uma estratégia análoga foi aplicada às operações de acumulação intensiva em atenção e softmax. Esta escolha permite avaliar o impacto do LNS nas operações de maior custo computacional — as multiplicações de matrizes — sem incorrer na instabilidade numérica da acumulação puramente logarítmica.

Um processo equivalente ocorreu com o ficheiro `tinystories/tiny/tiny_lms16_lms32acc.cpp` em que, em vez de usar **fp32** para a acumulação da soma, usou-se a simulação de **lms32** (drop-in replacement).

Foi também estado todos os modelos com **bf16** com acumulação da soma em **fp32** (ficheiro `tinystories/tiny/tiny_bf16.cpp`).

É de realçar que, sem a acumulação da soma com **fp32** em **bf16** e **lms16**, os modelos não conseguiam dar output lógico de texto.

3.4.3 Inferência **lms8** vs **bf8**

Inferência com ambos os formatos de 8 bits foi testada, mas o output do modelo era ou a repetição do mesmo token ou acabava numa divisão por zero, caso do **lms8**.

3.4.4 Resultados de Inferência

Todos os modelos foram corridos com os parâmetros default exceto o tokenizer que muda de acordo com o formato LNS/BF.

Parâmetro	Descrição	Valor Default
Temperature	Controla criatividade; 0.0 é determinístico, 1.0 é criativo	1.0
Top-p	Nucleus sampling; remove 1 – topp dos tokens menor prováveis	1.0
Steps	Máximo número de tokens da geração	256
Prompt	Texto inicial que o modelo usa como baseline para começar	NULL
rng_seed	Semente do gerador de números aleatórios; 0 usa system time	0
Mode	Determina como o modelo se comporta (generate/chat)	generate
System Prompt	Usado apenas em modo chat para maior instruction context	NULL

3.4.4.1 Stories 15M

3.4.4.1.1 lns16 (XF)

Once upon a time, there was a little girl named Lily. She loved to draw and color with her crayons. One day, she drew a beautiful picture of a rainbow with lots of colors. Her mom saw the picture and said, “Lily, that’s a pretty flower. You should try to make it even more beautiful.” Lily smiled and said, “I want to design a new picture of a rainbow!” Her mom gave her some paper and crayons and Lily started to draw. But then she got confused and drew the same big, bright colors. She said, “Mommy, this picture is not perfect.” Her mom said, “Oh no, I’m sorry. We can’t print it. But let’s draw another one.” Lily learned that sometimes things don’t go the way we want them to, but it’s important to keep trying and not give up.

3.4.4.1.2 lns16 (XMB)

One day, a boy named Tim and a girl named Sue went to the beach. They saw a lot of water and a big, pretty sun. They wanted to play and splash in the water. Tim had a toy boat that he would push in the water. Sue had a ball that she liked to throw. Tim said, “Let’s race our boats!” Sue agreed and they put their boats in the water. Tim’s boat went very fast, and Sue’s ball went in the water. They laughed and clapped their hands as they watched the boats swim. After a while, Tim felt tired. He said, “I’m hungry. Let’s stop and eat.” Sue agreed and they started to eat their lunch. They sat on the sand and watched the boats in the water. They had a fun day at the beach and went home happy.

3.4.4.1.3 bf16

Once upon a time, there was a little girl named Lily. She had a big brother named Max who was very dependable. Max always helped Lily when she needed it. One day, Lily wanted to play with her toys but Max said no. Lily was sad and angry. She wanted to play with Max’s toys. Lily’s mom noticed her daughter was upset and asked her what was wrong. Lily explained that Max wouldn’t let her play with his toys. Lily’s mom talked to Max and told him that Lily was being mean. Max didn’t listen and kept saying mean things. Lily felt better and decided to talk to Max. She told him that she didn’t want to play with him and that it was okay to be mean. Max realized he was being mean and gave Lily a toy to play with. They both played together and had fun.

3.4.4.2 Stories 42M

3.4.4.2.1 lns16 (XF)

Once upon a time, there was a little boy named Tim. Tim was very excited because he was going on a holiday with his family. They were going to the beach! Tim loved the beach because he could play in the sand and swim in the sea. One day, Tim's family decided to have a picnic in the park. They packed sandwiches and fruit to eat. But when they went to the beach, they saw that the sand was not there! They looked everywhere but couldn't find it. Tim was sad because he really wanted to eat the sandwich. Suddenly, they heard a loud noise and saw a big wave coming towards them. They were scared because it was a storm. But then, the wave brought a big box with them. They opened the box and found a treasure! It was a big toy boat that Tim and his family could use. They were so happy and thanked the wave for bringing the treasure.

3.4.4.2.2 lns16 (XMB)

Once upon a time, there was a little girl named Lily. She loved to help her mom in the kitchen. One day, her mom asked her to get some ice from the freezer. Lily was so happy to help! She ran to the freezer and opened it. Inside, she found a rare ice cream. Lily was so excited to eat it, but then she saw something she didn't expect. The ice cream started to melt in her hands! She quickly took it off and ran to her mom. "Mommy, the ice cream is melting! It's making me panic!" she exclaimed. Her mom laughed and said, "Don't worry, Lily. It's just a melted ice cream. Let's go back to the kitchen and get more." Lily was happy to get more ice cream, but she knew she had to wait for it to melt away.

3.4.4.2.3 bf16

Once upon a time, there was a little boy named Tim. Tim was a pupil in a small school. He had a friend named Sam. Sam was a very reliable friend. They liked to play and laugh together. One day, Tim and Sam went to play outside. They saw a big tree and wanted to climb it. Tim said, "Let's go up, Sam!" Sam agreed, and they started to climb the tree. As they climbed, they saw a bird in the tree. The bird said, "Hello, Tim and Sam!" Tim and Sam were very surprised. They did not know that birds could talk. The bird said, "I am a magic bird. If you help me, I will give you a surprise." Tim and Sam thought about it and said, "Yes, we can help you!" The magic bird told Tim and Sam to close their eyes. When they opened them, they were now in a magical world. They met many animals and had many fun adventures. They were very happy and thankful for the magic bird and his help.

3.4.5 Análise

A produção de texto coerente pelos modelos *TinyStories* após conversão directa $\text{fp32} \rightarrow \text{lns16}$, sem qualquer re-treino, confirma a viabilidade prática do **lns16 Q8.7** para inferência em redes neurais.

4 Conclusão e Trabalho Futuro

Este estágio aprofundou e alargou uma implementação LNS prévia em quatro direcções: operações de comparação e conversão, biblioteca de emulação, comparação estatística com BF e inferência em modelos de linguagem. Os resultados permitem tirar conclusões claras sobre os pontos fortes e as limitações do formato.

O LNS é inequivocamente superior em multiplicação e divisão — as operações dominantes em redes neuronais. No regime de 8 bits, o `bf8` vence o `lns8` em todas as operações em todas as bandas de magnitude testadas, embora na multiplicação e divisão estas diferenças sejam menores; no regime de 16 bits, o `lns16` mantém vantagem consistente em divisão e em erro absoluto de multiplicação. A razão é estrutural: multiplicação e divisão são exactas no domínio logarítmico, reduzindo-se a operações inteiras sem erro de arredondamento de mantissa. Em contrapartida, a adição e a subtracção requerem a avaliação das funções de Gauss logarítmicas f^+ e f^- por tabela de consulta, introduzindo erro de aproximação que o IEEE 754 não sofre. Esta assimetria é o traço definidor do LNS e deve informar qualquer decisão de adopção: o formato é mais vantajoso em cargas de trabalho dominadas por produtos de matrizes, e menos adequado a pipelines com acumulação intensiva.

A viabilidade do `lns16 Q8.7` para inferência foi confirmada empiricamente. A conversão directa de pesos `fp32` para `lns16`, sem re-treino, produz texto coerente nos modelos `stories15M` e `stories42M`, corroborando que o erro introduzido nas multiplicações de matrizes é suficientemente pequeno para preservar a qualidade da saída. A abordagem híbrida adoptada — acumulação em `fp32/lns32`, multiplicações em `lns16` — é um compromisso pragmático que delimita claramente onde o LNS contribui valor e onde a sua fraqueza aritmética obrigaria a mitigação adicional.

Como **trabalho futuro**, os eixos mais imediatos são: implementar métodos de aproximação de maior ordem — diferenças divididas de Newton e Chebyshev por troços — para reduzir o número de intervalos necessários em f^- e tornar praticáveis os formatos `lns32` e `lns64`; avaliar o LNS em arquitecturas convolucionais e em modelos de linguagem de maior escala; e explorar re-treino ou ajuste fino com representação LNS para recuperar a precisão perdida na conversão directa, potencialmente eliminando a necessidade da abordagem híbrida nas operações de acumulação.

Bibliografia

- [1] B. Parhami, «Logarithmic Number Systems: Theory and Applications», *Advances in Computers*, vol. 117, p. 106800, 2020.
- [2] J. N. Coleman, E. I. Chester, C. I. Softley, e J. Kadlec, «Lookup-Tables for Logarithmic Number System Operations», *IEEE Transactions on Computers*, vol. 49, n.º 7, pp. 702–715, 2000.
- [3] M. Christ e others, «Low-Precision Logarithmic Arithmetic for Neural Network Accelerators», em *Proceedings of the IEEE 33rd International Conference on Application-specific Systems, Architectures and Processors (ASAP)*, 2022.
- [4] Y. Wu e others, «PVU: A Posit Vector Processor Unit Based on RISC-V Extension». 2025.
- [5] B. D. Rouhani e others, «Microscaling Data Formats for Deep Learning». 2023.
- [6] E. Islamoglu e others, «MXDOTP: A RISC-V ISA Extension for Enabling Microscaling (MX) Floating-Point Dot Products». 2025.
- [7] S. Han, H. Mao, e W. J. Dally, «Deep Compression: Compressing Deep Neural Networks with Pruning, Trained Quantization and Huffman Coding». 2015.
- [8] A. Karpathy, «llama2.c». 2023.